UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
Posgrado en Ciencia e Ingeniería de la Computación

Aprendizaje Profundo

Redes densas con PyTorch

Bere & Ricardo Montalvo Lezama

Octubre 2020

Bibliotecas para aprendizaje profundo

- Modelo de programación sencillo de álgebra lineal.
- Abstracciones comunes de redes neuronales.
- Ejecución en CPU y GPU.
- Diferenciación automática y optimizadores.
- Visualización, serialización, trazas, distribución.

Historia

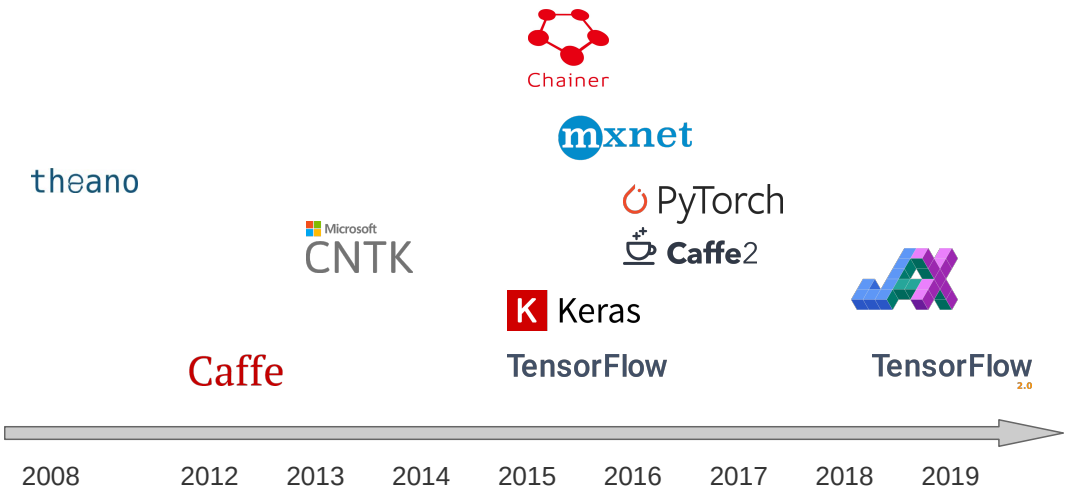
Chainer
mxnet
theano
PyTorch
Microsoft
CNTK
Caffe2
Keras
Caffe
TensorFlow
TensorFlow
2.0
2008
2012
2013
2014
2015
2016
2017
2018
2019

Tensores

- Un tensor es un arreglo multidimensional.

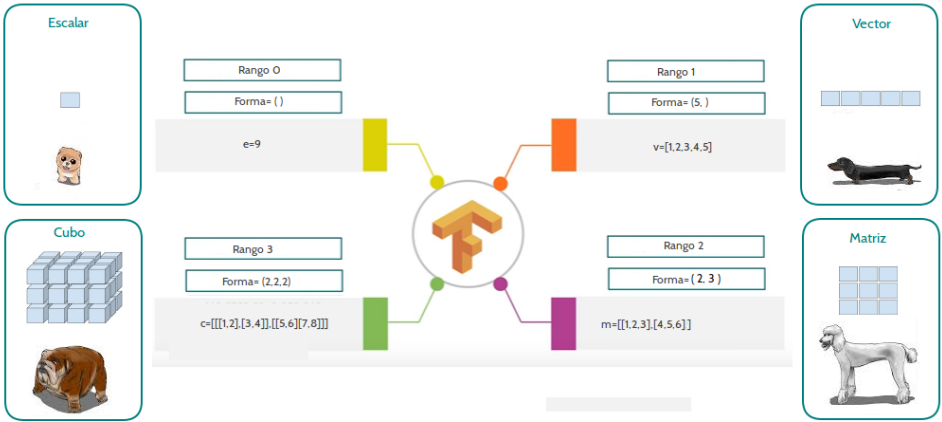

Gráficas de cómputo

- Representación de una composición de funciones donde las variables son tensores (datos y parámetros).

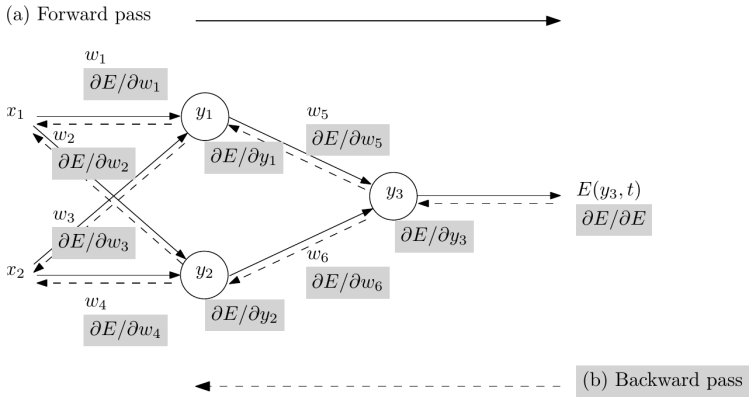

Fuente: Automatic Differentiation in Machine Learning: a Survey

Estáticas vs dinámicas

Define-and- Run
Estática

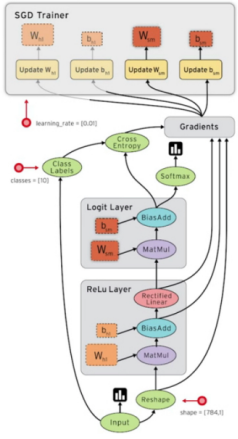

Define-by-Run
Dinámica

A graph is created on the fly


```
from torch.autograd import Variable

x = Variable(torch.randn(1, 10))
prev_h = Variable(torch.randn(1, 20))
W_h = Variable(torch.randn(20, 20))
W_x = Variable(torch.randn(20, 10))
```

Fuente: tensorflow.org

Estáticas vs dinámicas

Define-and- Run
Estática

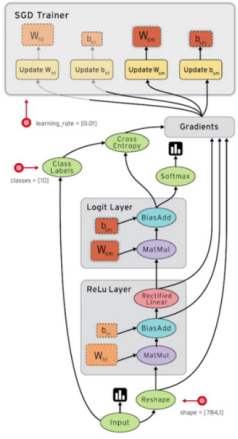

Define-by-Run
Dinámica

A graph is created on the fly

```
from torch.autograd import Variable

x = Variable(torch.randn(1, 10))
prev_h = Variable(torch.randn(1, 20))
W_h = Variable(torch.randn(20, 20))
W_x = Variable(torch.randn(20, 10))

i2h = torch.mm(W_x, x.t())
h2h = torch.mm(W_h, prev_h.t())
```

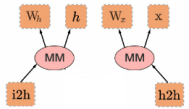

Fuente: tensorflow.org

Estáticas vs dinámicas

Define-and- Run
Estática

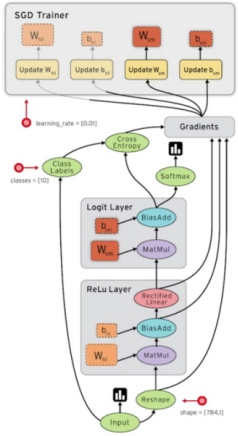

Define-by-Run
Dinámica

A graph is created on the fly

```
from torch.autograd import Variable

x = Variable(torch.randn(1, 10))
prev_h = Variable(torch.randn(1, 20))
W_h = Variable(torch.randn(20, 20))
W_x = Variable(torch.randn(20, 10))

i2h = torch.mm(W_x, x.t())
h2h = torch.mm(W_h, prev_h.t())
next_h = i2h + h2h
```

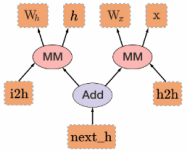

Fuente: tensorflow.org

Estáticas vs dinámicas

Define-and- Run
Estática

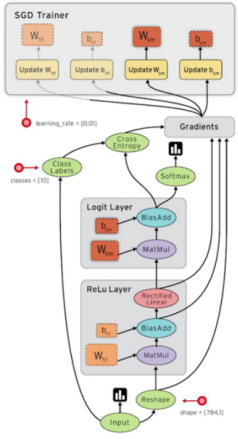

Define-by-Run
Dinámica

A graph is created on the fly

```
from torch.autograd import Variable

x = Variable(torch.randn(1, 10))
prev_h = Variable(torch.randn(1, 20))
W_h = Variable(torch.randn(20, 20))
W_x = Variable(torch.randn(20, 10))

i2h = torch.mm(W_x, x.t())
h2h = torch.mm(W_h, prev_h.t())
next_h = i2h + h2h
next_h = next_h.tanh()
```

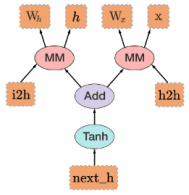

Fuente: tensorflow.org

Gráficas y bibliotecas

- Estática

- Dinámica

Interfaces de PyTorch

- Alto Nivel
  - Apilando capas con nn.Sequential.
- Medio Nivel
  - Heredando de nn.Module.
- Bajo Nivel
  - Usando primitivas y definiendo parámetros.

Clasificación vs Regresión

Regresión

¿ Cuál será la temperatura del día de mañana ?

Clasificación

¿ El día de mañana será caluroso o frío ?

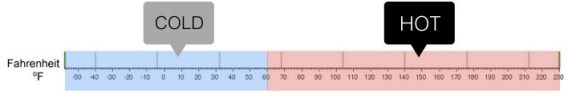

Regresión lineal simple (I)

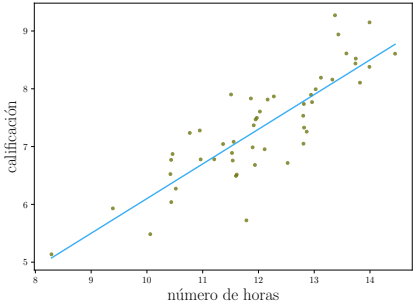

- Modelo:

$$\hat{y} = wx + b$$

Regresión lineal simple (II)

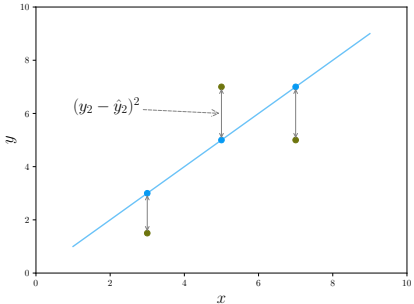

- Modelo:

$$\hat{y} = wx + b$$

- Función de error:

$$E(w, b) = \frac{1}{2} \sum_{i=1}^{n} (y - \hat{y})^2$$

Regresión lineal simple (III)

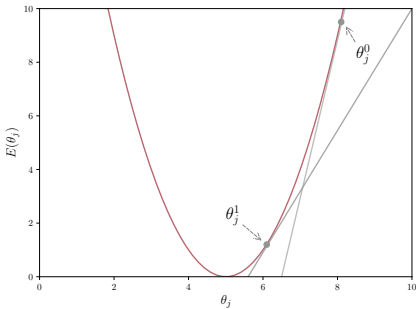

- Modelo:

$$\hat{y} = wx + b$$

- Función de error:

$$E(w, b) = \frac{1}{2} \sum_{i=1}^{n} (y - \hat{y})^2$$

- Optimización de la función de error:

$$w := w - \alpha \frac{\partial}{\partial w} E(w, b)$$

$$b := b - \alpha \frac{\partial}{\partial b} E(w, b)$$

Conjunto de datos Iris

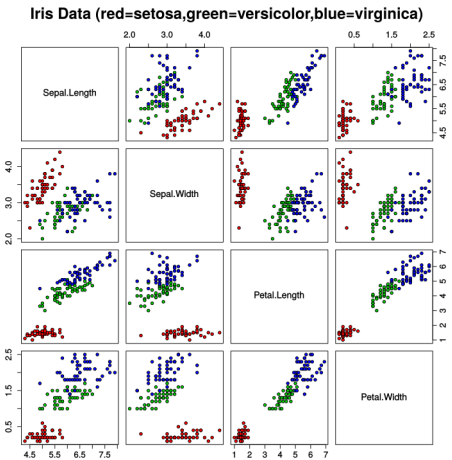

Conjunto de datos de tres especies de Iris.

- Setosa.
- Versicolour.
- Virginica.

Atributos:

- Largo Sépalo.
- Ancho Sépalo.
- Largo Pétalo.
- Ancho Sépálo.

Regresión logística

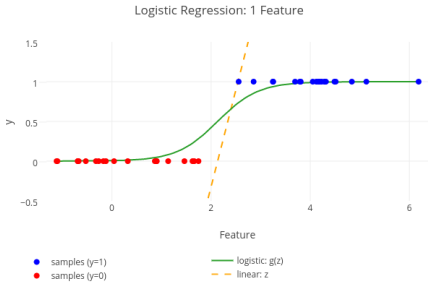

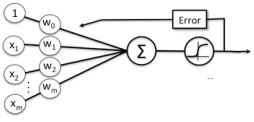

- Modelo:

$$P(y|x_i, \theta) = \hat{y} = f\frac{1}{1 + e^{wx+b}}$$

- Función de error: entropía cruzada binaria.

$$E = -\frac{1}{m}\sum_{i=1}^{m}(y\log(\hat{y}) + (1-y)log(1-\hat{y}))$$

- Optimización de la función de error:

$$w := w - \alpha\frac{\partial}{\partial w}E(w, b)$$

$$b := b - \alpha\frac{\partial}{\partial b}E(w, b)$$

- Métrica: exactitud.

$$Ex = \frac{\#\text{ predicciones correctas}}{\#\text{ total de predicciones}}$$

Entropía cruzada binaria.

$$E = (y)(-\log(\hat{y})) + (1-y)(-log(1-\hat{y}))$$

Etiqueta y	Predicción $\hat{y}$	Entropía binaria	Pérdida
0	0.9	2.303	alta
0	0.1	0.105	baja
1	0.9	0.105	baja
1	0.1	2.303	alta

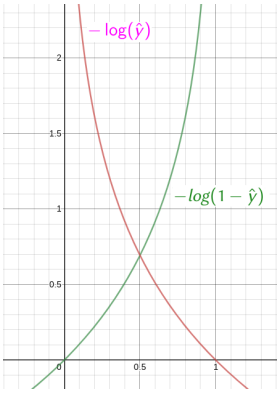

Representación de imágenes

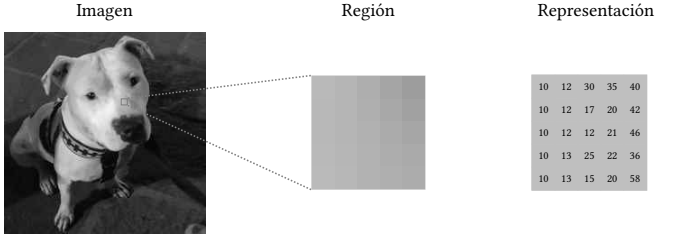

Perceptrón multicapa

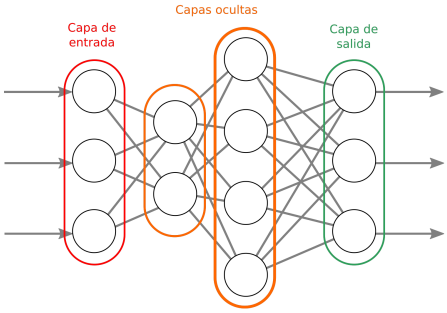

Entrenamiento:

- Paso 1: carga el lote de entrenamiento datos.
- Paso 2: propagación hacia adelante para obtener las predicciones y calcular el error.
- Paso 3: retropropagar el error.
- Paso 4: actualizar los pesos.

- Activación de la j-ésima neurona de la i-ésima capa:

$$a_j^i = f(\sum_{i=1}^{n} x_i w_i + b).$$

- Función de error: entropía cruzada categórica.

$$E = -\frac{1}{m}\sum_{i=1}^{m}(y \log(\hat{y}))$$

- Optimización de la función de error:

$$w := w - \alpha \frac{\partial}{\partial w} E(w, b)$$

$$b := b - \alpha \frac{\partial}{\partial b} E(w, b)$$

- Métrica: exactitud.

$$Ex = \frac{\#\text{ predicciones correctas}}{\#\text{ total de predicciones}}$$

Ventajas de PyTorch

- Arquitecturas, modelos preentrenados y conjuntos de datos.
  - torchvison, torchtext, torchaudio.
- Visualización y entrenamiento.
  - Tensorboard, skorch, Ignite, Lightning.
- Dominios especializados.
  - AllenNLP (lenguaje), BoTorch (optimización bayesiana), DGL (gráficas).
- Precisión mixta e interoperabilidad.
  - Apex/AMP, ONNX.